# PROJET 4 DATA ANALYST

## Réalisez une étude de santé publique avec R ou Python

## OBJECTIF DE CE NOTEBOOK

Bienvenue dans l'outil plébiscité par les analystes de données Jupyter.

Il s'agit d'un outil permettant de mixer et d'alterner codes, textes et graphique.

Cet outil est formidable pour plusieurs raisons:

- il permet de tester des lignes de codes au fur et à mesure de votre rédaction, de constater immédiatement le résultat d'un instruction, de la corriger si nécessaire.
- De rédiger du texte pour expliquer l'approche suivie ou les résultats d'une analyse et de le mettre en forme grâce à du code html ou plus simple avec **Markdown**
- d'agrémenter de graphiques

Pour vous aider dans vos premiers pas à l'usage de Jupyter et de Python, nous avons rédigé ce notebook en vous indiquant les instructions à suivre.

Il vous suffit pour cela de saisir le code Python répondant à l'instruction donnée.

Vous verrez de temps à autre le code Python répondant à une instruction donnée mais cela est fait pour vous aider à comprendre la nature du travail qui vous est demandée.

Et garder à l'esprit, qu'il n'y a pas de solution unique pour résoudre un problème et qu'il y a autant de résolutions de problèmes que de développeurs ;)...

# Etape 1 - Importation des librairies et chargement des fichiers

## 1.1 - Importation des librairies

```
#Importation de la librairie Pandas
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

## 1.2 - Chargement des fichiers Excel

```
#Importation du fichier population.csv
population = pd.read_csv('data/population.csv')

#Importation du fichier dispo_alimentaire.csv
dispo_alimentaire = pd.read_csv('data/dispo_alimentaire.csv')

#Importation du fichier aide_alimentaire.csv
aide_alimentaire = pd.read_csv('data/aide_alimentaire.csv')

#Importation du fichier sous_nutrition.csv
sous_nutrition = pd.read_csv('data/sous_nutrition.csv')
```

# Etape 2 - Analyse exploratoire des fichiers

## 2.1 - Analyse exploratoire du fichier population

```
#Afficher les dimensions du dataset
print("Le tableau comporte {} observation(s) ou article(s)".format(population.shape[0]))
print("Le tableau comporte {} colonne(s)".format(population.shape[1]))
```

```
Le tableau comporte 1416 observation(s) ou article(s)
Le tableau comporte 3 colonne(s)
```

```
#Consulter le nombre de colonnes
population.shape[1]
#La nature des données dans chacune des colonnes
population.info()
#Le nombre de valeurs présentes dans chacune des colonnes
population.count()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1416 entries, 0 to 1415
Data columns (total 3 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   Zone    1416 non-null   object
 1   Année   1416 non-null   int64
 2   Valeur  1416 non-null   float64
dtypes: float64(1), int64(1), object(1)
memory usage: 33.3+ KB
```

| | 0 |
|---|---|
| **Zone** | 1416 |
| **Année** | 1416 |
| **Valeur** | 1416 |

**dtype:** int64

```
#Affichage les 5 premières lignes de la table
population.head(5)
```

| | Zone | Année | Valeur |
|---|---|---|---|
| 0 | Afghanistan | 2013 | 32269.589 |
| 1 | Afghanistan | 2014 | 33370.794 |
| 2 | Afghanistan | 2015 | 34413.603 |
| 3 | Afghanistan | 2016 | 35383.032 |
| 4 | Afghanistan | 2017 | 36296.113 |

Next steps: Generate code with population | View recommended plots | New interactive sheet

```
#Nous allons harmoniser les unités. Pour cela, nous avons décidé de multiplier la population par 1000
#Multiplication de la colonne valeur par 1000
population['Valeur'] = population['Valeur'] * 1000


#changement du nom de la colonne Valeur par Population
population.rename(columns = {'Valeur' : 'Population'}, inplace=True)


#Affichage les 5 premières lignes de la table pour voir les modifications
population.head(5)
```

| | Zone | Année | Population |
|---|---|---|---|
| 0 | Afghanistan | 2013 | 32269589.0 |
| 1 | Afghanistan | 2014 | 33370794.0 |
| 2 | Afghanistan | 2015 | 34413603.0 |
| 3 | Afghanistan | 2016 | 35383032.0 |
| 4 | Afghanistan | 2017 | 36296113.0 |

Next steps: Generate code with population | View recommended plots | New interactive sheet

## 2.2 - Analyse exploratoire du fichier disponibilité alimentaire

```
#Afficher les dimensions du dataset
print("Le tableau comporte {} observation(s) ou article(s)".format(dispo_alimentaire.shape[0]))
print("Le tableau comporte {} colonne(s)".format(dispo_alimentaire.shape[1]))
```

```
Le tableau comporte 15605 observation(s) ou article(s)
Le tableau comporte 18 colonne(s)
```

```
#Consulter le nombre de colonnes
dispo_alimentaire.shape[1]
```

```
18
```

```
#Affichage les 5 premières lignes de la table
dispo_alimentaire.head(5)
```

| | Zone | Produit | Origine | Aliments pour animaux | Autres Utilisations | Disponibilité alimentaire (Kcal/personne/jour) | Disponibilité alimentaire en quantité (kg/personne/an) | Disponibilité de matière grasse en quantité (g/personne/jour) | Di (g/ |
|---|---|---|---|---|---|---|---|---|---|
| **0** | Afghanistan | Abats Comestible | animale | NaN | NaN | 5.0 | 1.72 | 0.20 | |
| **1** | Afghanistan | Agrumes, Autres | vegetale | NaN | NaN | 1.0 | 1.29 | 0.01 | |
| **2** | Afghanistan | Aliments pour enfants | vegetale | NaN | NaN | 1.0 | 0.06 | 0.01 | |
| **3** | Afghanistan | Ananas | vegetale | NaN | NaN | 0.0 | 0.00 | NaN | |
| **4** | Afghanistan | Bananes | vegetale | NaN | NaN | 4.0 | 2.70 | 0.02 | |

Next steps: Generate code with dispo_alimentaire | View recommended plots | New interactive sheet

```
#remplacement des NaN dans le dataset par des 0
dispo_alimentaire.fillna(0, inplace=True)
```

```
#multiplication de toutes les lignes contenant des milliers de tonnes en Kg
dispo_alimentaire.loc[:, 'Disponibilité intérieure': 'Variation de stock'] = dispo_alimentaire.loc[:, 'Disponibilité int
dispo_alimentaire.loc[:, 'Aliments pour animaux':'Autres Utilisations'] = dispo_alimentaire.loc[:, 'Aliments pour animau
```

```
# Remplacement de la colonne Nourriture par Aliments pour humains
dispo_alimentaire.rename(columns={'Nourriture':'Aliments pour humains'}, inplace=True)
```

```
#Affichage les 5 premières lignes de la table
dispo_alimentaire.head(5)
```

| | Zone | Produit | Origine | Aliments pour animaux | Autres Utilisations | Disponibilité alimentaire (Kcal/personne/jour) | Disponibilité alimentaire en quantité (kg/personne/an) | Disponibilité de matière grasse en quantité (g/personne/jour) | Di (g/ |
|---|---|---|---|---|---|---|---|---|---|
| **0** | Afghanistan | Abats Comestible | animale | 0.0 | 0.0 | 5.0 | 1.72 | 0.20 | |
| **1** | Afghanistan | Agrumes, Autres | vegetale | 0.0 | 0.0 | 1.0 | 1.29 | 0.01 | |
| **2** | Afghanistan | Aliments pour enfants | vegetale | 0.0 | 0.0 | 1.0 | 0.06 | 0.01 | |
| **3** | Afghanistan | Ananas | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | 0.00 | |
| **4** | Afghanistan | Bananes | vegetale | 0.0 | 0.0 | 4.0 | 2.70 | 0.02 | |

Next steps: Generate code with dispo_alimentaire | View recommended plots | New interactive sheet

## 2.3 - Analyse exploratoire du fichier aide alimentaire

```
#Afficher les dimensions du dataset
print("Le tableau comporte {} observation(s) ou article(s)".format(aide_alimentaire.shape[0]))
print("Le tableau comporte {} colonne(s)".format(aide_alimentaire.shape[1]))
```

```
Le tableau comporte 1475 observation(s) ou article(s)
Le tableau comporte 4 colonne(s)
```

```
#Consulter le nombre de colonnes
aide_alimentaire.shape[1]
```

```
4
```

```
#Affichage les 5 premières lignes de la table
aide_alimentaire.head(5)
```

| | Pays bénéficiaire | Année | Produit | Valeur |
|---|---|---|---|---|
| 0 | Afghanistan | 2013 | Autres non-céréales | 682 |
| 1 | Afghanistan | 2014 | Autres non-céréales | 335 |
| 2 | Afghanistan | 2013 | Blé et Farin | 39224 |
| 3 | Afghanistan | 2014 | Blé et Farin | 15160 |
| 4 | Afghanistan | 2013 | Céréales | 40504 |

Next steps: Generate code with aide_alimentaire | View recommended plots | New interactive sheet

```
#changement du nom de la colonne Pays bénéficiaire par Zone
aide_alimentaire.rename(columns={'Pays bénéficiaire' : 'Zone'}, inplace=True)
```

```
#Multiplication de la colonne Aide_alimentaire qui contient des tonnes par 1000 pour avoir des kg
aide_alimentaire['Valeur'] = aide_alimentaire['Valeur'] * 1000
aide_alimentaire.rename(columns={'Valeur':'Aide_alimentaire'}, inplace=True)
```

```
#Affichage les 5 premières lignes de la table
aide_alimentaire.head(5)
```

| | Zone | Année | Produit | Aide_alimentaire |
|---|---|---|---|---|
| 0 | Afghanistan | 2013 | Autres non-céréales | 682000 |
| 1 | Afghanistan | 2014 | Autres non-céréales | 335000 |
| 2 | Afghanistan | 2013 | Blé et Farin | 39224000 |
| 3 | Afghanistan | 2014 | Blé et Farin | 15160000 |
| 4 | Afghanistan | 2013 | Céréales | 40504000 |

Next steps: Generate code with aide_alimentaire | View recommended plots | New interactive sheet

## 2.3 - Analyse exploratoire du fichier sous nutrition

```
#Afficher les dimensions du dataset
print("Le tableau comporte {} observation(s) ou article(s)".format(sous_nutrition.shape[0]))
print("Le tableau comporte {} colonne(s)".format(sous_nutrition.shape[1]))
```

```
Le tableau comporte 1218 observation(s) ou article(s)
Le tableau comporte 3 colonne(s)
```

```
#Consulter le nombre de colonnes
sous_nutrition.shape[1]
```

```
3
```

```
#Afficher les 5 premières lignes de la table
sous_nutrition.head(5)
```

| | Zone | Année | Valeur |
|---|---|---|---|
| 0 | Afghanistan | 2012-2014 | 8.6 |
| 1 | Afghanistan | 2013-2015 | 8.8 |
| 2 | Afghanistan | 2014-2016 | 8.9 |
| 3 | Afghanistan | 2015-2017 | 9.7 |
| 4 | Afghanistan | 2016-2018 | 10.5 |

Next steps: Generate code with sous_nutrition | View recommended plots | New interactive sheet

## 3.1 - Proportion de personnes en sous nutrition

```
#changement du nom de la colonne Valeur par sous_nutrition
sous_nutrition.rename(columns = {'Valeur' : 'Sous_nutrition'}, inplace=True)
```

```
#Conversion de la colonne sous nutrition en numérique
sous_nutrition['Sous_nutrition'] = pd.to_numeric(sous_nutrition['Sous_nutrition'], errors='coerce')
```

```
#Conversion de la colonne (avec l'argument errors=coerce qui permet de convertir automatiquement les lignes qui ne sont
#Puis remplacement des NaN en 0
sous_nutrition.fillna(0, inplace=True)
```

```
#Multiplication de la colonne sous_nutrition par 1000000
sous_nutrition['Sous_nutrition'] = sous_nutrition['Sous_nutrition'] * 1000000
```

```
#Afficher les 5 premières lignes de la table
sous_nutrition.head(5)
```

| | Zone | Année | Sous_nutrition |
|---|---|---|---|
| 0 | Afghanistan | 2012-2014 | 8600000.0 |
| 1 | Afghanistan | 2013-2015 | 8800000.0 |
| 2 | Afghanistan | 2014-2016 | 8900000.0 |
| 3 | Afghanistan | 2015-2017 | 9700000.0 |
| 4 | Afghanistan | 2016-2018 | 10500000.0 |

Next steps: Generate code with sous_nutrition | View recommended plots | New interactive sheet

```
# Rajouter une colonne Année median dans la table Sous-nutrition
years_median = []
for year in sous_nutrition['Année']:
    start_year, end_year = map(int, year.split('-'))
    years_median.append((end_year+start_year)/2)
sous_nutrition['Année médian'] = years_median
sous_nutrition['Année médian'] = sous_nutrition['Année médian'].astype(int)
```

```
# Il faut tout d'abord faire une jointure entre la table population et la table sous nutrition, en ciblant l'année 2017
# dans le lexique des données on considère que l'année ciblée représente la médiane d'un intervalle de 3 ans donc 2017 =
# Donc cela finit forcément par 2018 et un regex peut être appliqué pour filtrer uniquement sur ces dates
population_sous_nutrition_merge = pd.merge(population, sous_nutrition, on='Zone', suffixes=('_population', '_sous_nutrit
population_sous_nutrition_2017 = population_sous_nutrition_merge.loc[
    (population_sous_nutrition_merge['Année_population'] == 2017) &
    (population_sous_nutrition_merge['Année médian']==2017)
    ]
```

```
#Affichage du dataset
population_sous_nutrition_2017.head()
```

| | Zone | Année_population | Population | Année_sous_nutrition | Sous_nutrition | Année médian |
|---|---|---|---|---|---|---|
| **28** | Afghanistan | 2017 | 36296113.0 | 2016-2018 | 10500000.0 | 2017 |
| **64** | Afrique du Sud | 2017 | 57009756.0 | 2016-2018 | 3100000.0 | 2017 |
| **100** | Albanie | 2017 | 2884169.0 | 2016-2018 | 100000.0 | 2017 |
| **136** | Algérie | 2017 | 41389189.0 | 2016-2018 | 1300000.0 | 2017 |
| **172** | Allemagne | 2017 | 82658409.0 | 2016-2018 | 0.0 | 2017 |

Next steps: Generate code with population_sous_nutrition_2017 | View recommended plots | New interactive sheet

```
# Calcul et affichage du nombre de personnes en état de sous-nutrition au niveau mondial
sous_nutrition_mondiale = population_sous_nutrition_2017['Sous_nutrition'].sum()
ratio_sous_nutrition_mondiale = sous_nutrition_mondiale / population_sous_nutrition_2017['Population'].sum()

print("Nombre de personnes en sous-nutrition en 2017 au niveau mondial : {} ".format(sous_nutrition_mondiale))
print("Ratio personnes en sous-nutrition en 2017 au niveau mondial : {}%".format(round(ratio_sous_nutrition_mondiale*100
```

```
Nombre de personnes en sous-nutrition en 2017 au niveau mondial : 535700000.0
Ratio personnes en sous-nutrition en 2017 au niveau mondial : 7.1%
```

```
#Calcul et affichage du nombre de personnes en état de sous nutrition poru chaque pays
gp_population_sous_nutrition_2017 = population_sous_nutrition_2017.groupby('Zone')[['Sous_nutrition', 'Population']].agg

# Création d'une colonne Prop_sous_nutrition`
gp_population_sous_nutrition_2017['Proportion_pays_sous_nutri(%)'] = round((gp_population_sous_nutrition_2017['Sous_nutr
top_10_pays_prop_sous_nutri_2017 = gp_population_sous_nutrition_2017.sort_values('Proportion_pays_sous_nutri(%)', ascend
top_10_pays_prop_sous_nutri_2017 = top_10_pays_prop_sous_nutri_2017.loc[:, ['Zone', 'Proportion_pays_sous_nutri(%)']]

# Création du graphique
ax = top_10_pays_prop_sous_nutri_2017.plot(kind='barh', x='Zone')
plt.xlabel('Proportion (en %)')
plt.ylabel('')
```

```
plt.legend('')
ax.invert_yaxis()
plt.title('Top pays en sous-nutrition')
plt.show()

top_10_pays_prop_sous_nutri_2017.head(10)
```

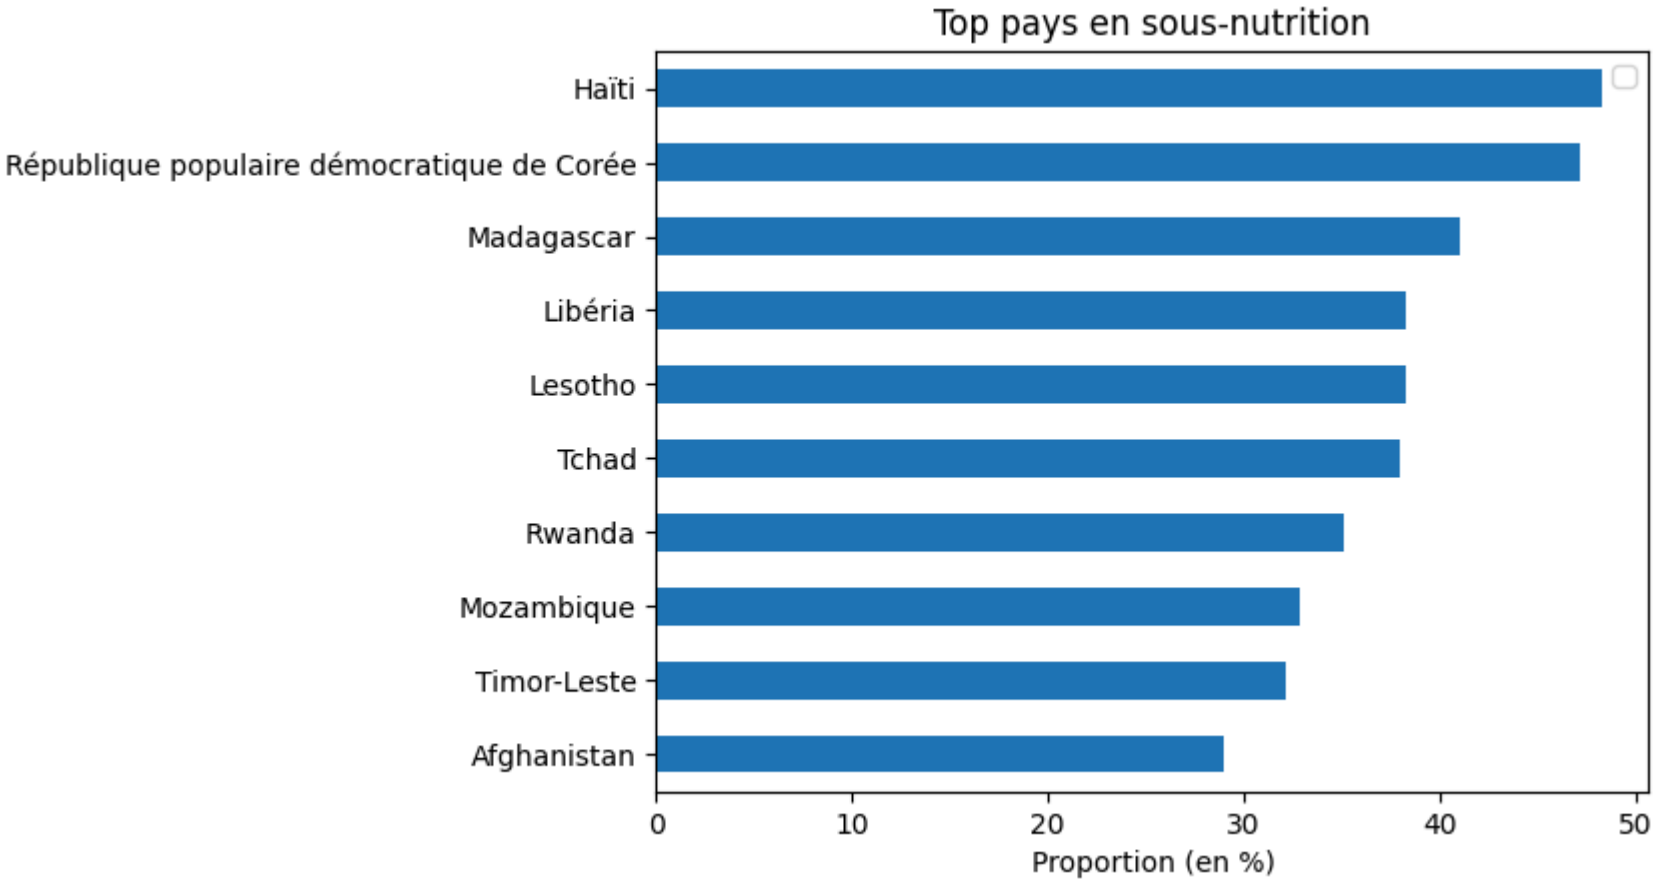


| | Zone | Proportion_pays_sous_nutri(%) |
|---|---|---|
| **72** | Haïti | 48.26 |
| **151** | République populaire démocratique de Corée | 47.19 |
| **99** | Madagascar | 41.06 |
| **95** | Libéria | 38.28 |
| **91** | Lesotho | 38.25 |
| **174** | Tchad | 37.96 |
| **143** | Rwanda | 35.06 |

| | | |
|---|---|---|
| **112** | Mozambique | 32.81 |
| **177** | Timor-Leste | 32.17 |
| **0** | Afghanistan | 28.93 |

Next steps: Generate code with top_10_pays_prop_sous_nutri_2017 | View recommended plots | New interactive sheet

```
total_sous_nutrition = population_sous_nutrition_2017['Sous_nutrition'].sum()
total_population = population_sous_nutrition_2017['Population'].sum()
proportion_personnes_sous_nutrition = round((total_sous_nutrition / total_population)*100, 2)
print('Total personnes en sous-nutrition : {}'.format(total_sous_nutrition))
print('Proportion en sous-nutrition : {}'.format(proportion_personnes_sous_nutrition))
```

```
Total personnes en sous-nutrition : 535700000.0
Proportion en sous-nutrition : 7.1
```

## 3.2 - Nombre théorique de personne qui pourrait être nourries

```
#Combien mange en moyenne un être humain ? Femme: 2000kcal / jour et Homme 2500 kcal/ jour
#Source => https://www.vidal.fr/sante/nutrition/equilibre-alimentaire-adulte/recommandations-nutritionnelles-adulte.html
moyenne_kcal_jour_hab = (2500 + 2000) / 2
```

```
#On commence par faire une jointure entre le data frame population et Dispo_alimentaire afin d'ajouter dans ce dernier l
population_dispo_alimentaire_merge = pd.merge(population, dispo_alimentaire, on='Zone').fillna(0)
df_population_dispo_alimentaire_2017 = population_dispo_alimentaire_merge.loc[
    population_dispo_alimentaire_merge['Année'] == 2017]
```

```
#Affichage du nouveau dataframe
df_population_dispo_alimentaire_2017.head(10)
```

| | Zone | Année | Population | Produit | Origine | Aliments pour animaux | Autres Utilisations | Disponibilité alimentaire (Kcal/personne/jour) | Disponibilité alimentaire en quantité (kg/personne/an) | m ( |
|---|---|---|---|---|---|---|---|---|---|---|
| **240** | Afghanistan | 2017 | 36296113.0 | Abats Comestible | animale | 0.0 | 0.0 | 5.0 | 1.72 | |
| **241** | Afghanistan | 2017 | 36296113.0 | Agrumes, Autres | vegetale | 0.0 | 0.0 | 1.0 | 1.29 | |
| **242** | Afghanistan | 2017 | 36296113.0 | Aliments pour enfants | vegetale | 0.0 | 0.0 | 1.0 | 0.06 | |
| **243** | Afghanistan | 2017 | 36296113.0 | Ananas | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | |
| **244** | Afghanistan | 2017 | 36296113.0 | Bananes | vegetale | 0.0 | 0.0 | 4.0 | 2.70 | |
| **245** | Afghanistan | 2017 | 36296113.0 | Beurre, Ghee | animale | 0.0 | 0.0 | 23.0 | 1.17 | |
| **246** | Afghanistan | 2017 | 36296113.0 | Bière | vegetale | 0.0 | 0.0 | 0.0 | 0.09 | |
| **247** | Afghanistan | 2017 | 36296113.0 | Blé | vegetale | 0.0 | 0.0 | 1369.0 | 160.23 | |
| **248** | Afghanistan | 2017 | 36296113.0 | Boissons Alcooliques | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | |
| **249** | Afghanistan | 2017 | 36296113.0 | Café | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | |

Next steps: Generate code with df_population_dispo_alimentaire_2017 View recommended plots New interactive sheet

```
#Création de la colonne dispo_kcal avec calcul des kcal disponibles mondialement

# On groupe par zone la somme de toutes les kcal alimentaires dispo par personne
groupe_zone_pop_dispo_calories = df_population_dispo_alimentaire_2017.groupby('Zone')[['Disponibilité alimentaire (Kcal/
    'Disponibilité alimentaire (Kcal/personne/jour)' : 'sum',
```

```
    'Population' : 'first'
}).reset_index()
total_calories_par_jour_pays = groupe_zone_pop_dispo_calories['Disponibilité alimentaire (Kcal/personne/jour)'] *\
groupe_zone_pop_dispo_calories['Population']

# total mondiale et calories mondiales
total_calories_mondiales_jour = total_calories_par_jour_pays.sum()
total_population_mondiale = groupe_zone_pop_dispo_calories['Population'].sum()

# On applique le résutat à la dataframe originale
population_dispo_alimentaire_merge['Dispo_kcal_mondial_personne_jour'] = total_calories_mondiales_jour / total_populatio


#Calcul du nombre d'humains pouvant être nourris

# Nombre d'humains nourris : total calories mondiale année / total calories mondiales recommandées par personne à l'année
nombre_humain_nourris = total_calories_mondiales_jour / moyenne_kcal_jour_hab

print('Nombre d\'humains nourris en 2017 : {}'.format(nombre_humain_nourris))
print('{} fois la population mondiale peut être nourrie en 2017'.format(
    round(nombre_humain_nourris/total_population_mondiale, 2)))
```

```
Nombre d'humains nourris en 2017 : 9297326501.036
1.28 fois la population mondiale peut être nourrie en 2017
```

## 3.3 - Nombre théorique de personne qui pourrait être nourrie avec les produits végétaux

```
#Transfert des données avec les végétaux dans un nouveau dataframe
df_vegetaux_2017 = df_population_dispo_alimentaire_2017[df_population_dispo_alimentaire_2017['Origine'] == 'vegetale']
df_vegetaux_2017.head()
```

| | Zone | Année | Population | Produit | Origine | Aliments pour animaux | Autres Utilisations | Disponibilité alimentaire (Kcal/personne/jour) | Disponibilité alimentaire en quantité (kg/personne/an) | D: ma (g/ |
|---|---|---|---|---|---|---|---|---|---|---|
| **241** | Afghanistan | 2017 | 36296113.0 | Agrumes, Autres | vegetale | 0.0 | 0.0 | 1.0 | 1.29 | |
| **242** | Afghanistan | 2017 | 36296113.0 | Aliments pour enfants | vegetale | 0.0 | 0.0 | 1.0 | 0.06 | |
| **243** | Afghanistan | 2017 | 36296113.0 | Ananas | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | |
| **244** | Afghanistan | 2017 | 36296113.0 | Bananes | vegetale | 0.0 | 0.0 | 4.0 | 2.70 | |
| **246** | Afghanistan | 2017 | 36296113.0 | Bière | vegetale | 0.0 | 0.0 | 0.0 | 0.09 | |

Next steps: Generate code with df_vegetaux_2017 | View recommended plots | New interactive sheet

```
#Calcul du nombre de kcal disponible pour les végétaux
# On regroupe de nouveau par zone, en calculant la population moyenne et le total kcal disponible par personne par jour
groupe_zone_dispo_calories_vegetales = df_vegetaux_2017.groupby('Zone')[['Disponibilité alimentaire (Kcal/personne/jour)
'Disponibilité alimentaire (Kcal/personne/jour)' : 'sum',
'Population' : 'first'}).reset_index()

total_calories_vegetales_par_jour_pays = groupe_zone_dispo_calories_vegetales['Disponibilité alimentaire (Kcal/personne/
groupe_zone_dispo_calories_vegetales['Population']

# Total calories aliments végétales par personnes par jour au niveau mondial
total_calories_vegetales_personne_mondiale = total_calories_vegetales_par_jour_pays.sum()


#Calcul du nombre d'humains pouvant être nourris avec les végétaux à l'année
nombre_humains_nourris_vegetal =  total_calories_vegetales_personne_mondiale / moyenne_kcal_jour_hab
print('Nombre d\'humains nourris par l\'alimentation végétale : {}'.format(round(nombre_humains_nourris_vegetal, 2)))
```

```
# Part du nombre d'humains nourris par l'alimentation végétale sur le nombre d'humains pouvant être nourris
part_nourriture_vegetale_globable = round((nombre_humains_nourris_vegetal/nombre_humain_nourris)*100, 0)
print('Part du végétal dans le nombre de personnes pouvant être nourries : {}'.format(part_nourriture_vegetale_globable)

print('{} fois la population mondiale peut être nourrie uniquement avec les produits végétaux en 2017'.format(
    round(nombre_humains_nourris_vegetal/total_population_mondiale, 2)))
```

```
Nombre d'humains nourris par l'alimentation végétale : 7671450760.67
Part du végétal dans le nombre de personnes pouvant être nourries : 83.0
1.05 fois la population mondiale peut être nourrie uniquement avec les produits végétaux en 2017
```

## 3.4 - Utilisation de la disponibilité intérieure

```
#Calcul de la disponibilité totale

# Semences + Pertes + Nourriture + Aliments pour animaux + Traitement + Autres utilisations = DI
# Production + Importations - Exportations + Variation de stock = DI

dispo_interieure_totale_sg1 = dispo_alimentaire[['Semences', 'Pertes', 'Aliments pour humains', 'Aliments pour animaux',
dispo_interieure_totale_sg2 = dispo_alimentaire[['Production','Importations - Quantité', 'Variation de stock']].sum()
dispo_interieure_totale_sg2['Exportations - Quantité'] = - dispo_alimentaire['Exportations - Quantité'].sum()


#création d'une boucle for pour afficher les différentes valeurs en fonction des colonnes aliments pour animaux, pertes,

# disponibilité alimentaire pour le sous-groupe 1 avec parcours via un for
data_disponibilite_interieure_sg1 = {}
for label, valeurs in dispo_interieure_totale_sg1.items():
  valeurs = abs(valeurs)
  data_disponibilite_interieure_sg1[label] = (valeurs / dispo_interieure_totale_sg1.sum()) * 100

data_disponibilite_interieure_sg1 = pd.DataFrame([data_disponibilite_interieure_sg1])

# Diagramme en camember est le meilleur pour montrer la répartition en pourcentage de quelques valeurs
# pour une même année
plt.pie(data_disponibilite_interieure_sg1.iloc[0],
```

```
            labels=data_disponibilite_interieure_sg1.columns,
            autopct='%1.1f%%')
plt.title('Répartition mondiale - Disponibilité intérieure SG1')
plt.show()

# disponibilité alimentaire pour le sous-groupe 2
data_disponibilite_interieure_sg2 = {}
for label, valeurs in dispo_interieure_totale_sg2.items():
  valeurs = abs(valeurs)
  data_disponibilite_interieure_sg2[label] = (valeurs / dispo_interieure_totale_sg2.sum()) * 100

data_disponibilite_interieure_sg2 = pd.DataFrame([data_disponibilite_interieure_sg2])

plt.pie(data_disponibilite_interieure_sg2.iloc[0],
            labels=data_disponibilite_interieure_sg2.columns,
            autopct='%1.1f%%')
plt.title('Répartition mondiale - Disponibilité intérieure SG2')
plt.show()
```

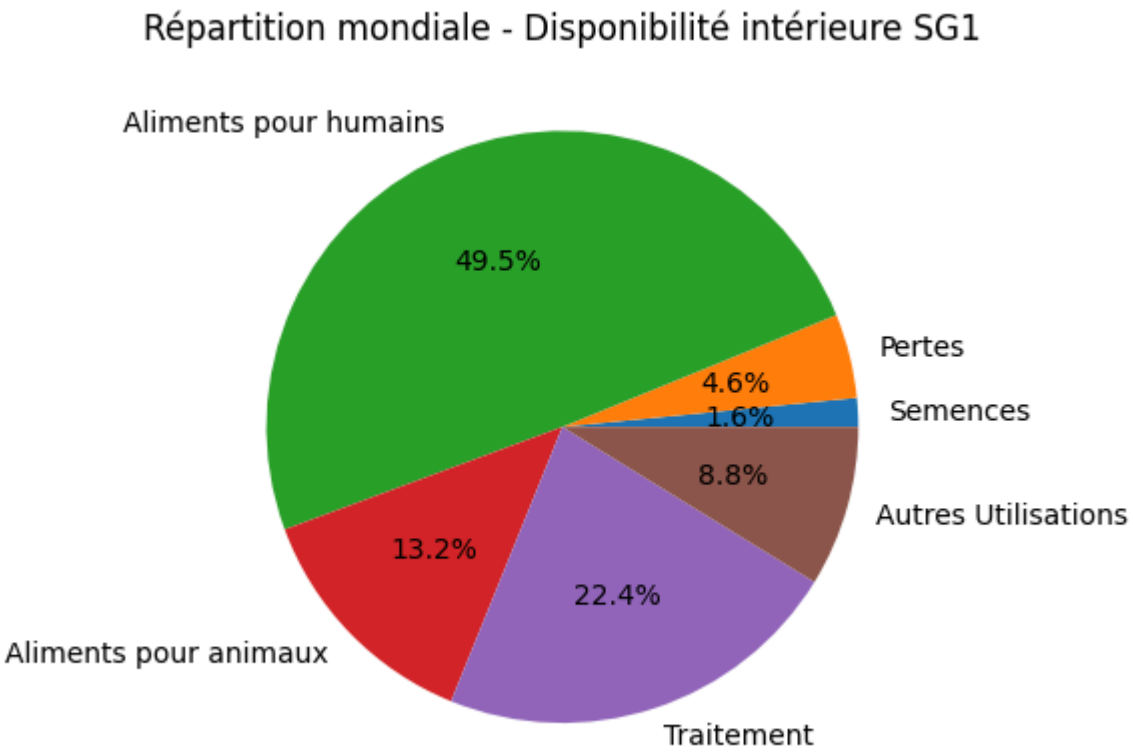
Répartition mondiale - Disponibilité intérieure SG1
Aliments pour humains
49.5%
Pertes
4.6%
1.6%
Semences
8.8%
Autres Utilisations
13.2%
22.4%
Aliments pour animaux
Traitement

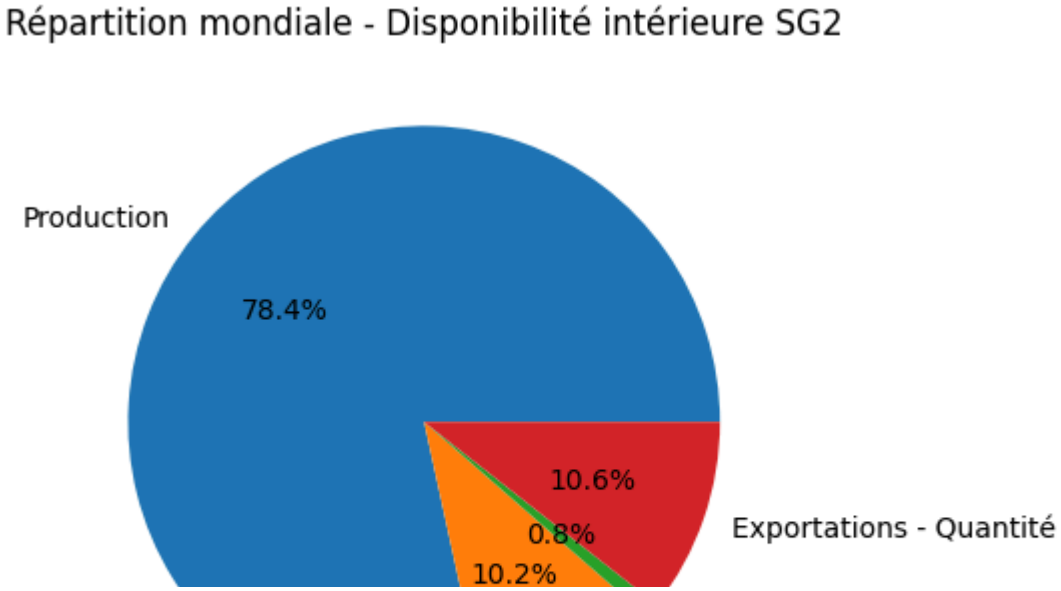
Répartition mondiale - Disponibilité intérieure SG2
Production
78.4%
10.6%
0.8%
Exportations - Quantité
10.2%

## 3.5 - Utilisation des céréales

```
#Création d'une liste avec toutes les variables
cereales_list = ['Blé', 'Riz (Eq Blanchi)', 'Orge', 'Maïs', 'Seigle', 'Avoine', 'Millet', 'Sorgho', 'Céréales, Autres']
```

```
#Création d'un dataframe avec les informations uniquement pour ces céréales
df_cereales = population_dispo_alimentaire_merge.loc[
    population_dispo_alimentaire_merge['Produit'].isin(cereales_list)
    & (population_dispo_alimentaire_merge['Année'] == 2017)]
df_cereales.head()
```

| | Zone | Année | Population | Produit | Origine | Aliments pour animaux | Autres Utilisations | Disponibilité alimentaire (Kcal/personne/jour) | Disponibilité alimentaire en quantité (kg/personne/an) | m ( |
|---|---|---|---|---|---|---|---|---|---|---|
| **247** | Afghanistan | 2017 | 36296113.0 | Blé | vegetale | 0.0 | 0.0 | 1369.0 | 160.23 | |
| **252** | Afghanistan | 2017 | 36296113.0 | Céréales, Autres | vegetale | 0.0 | 0.0 | 0.0 | 0.00 | |
| **272** | Afghanistan | 2017 | 36296113.0 | Maïs | vegetale | 200000000.0 | 0.0 | 21.0 | 2.50 | |
| **274** | Afghanistan | 2017 | 36296113.0 | Millet | vegetale | 0.0 | 0.0 | 3.0 | 0.40 | |
| **280** | Afghanistan | 2017 | 36296113.0 | Orge | vegetale | 360000000.0 | 0.0 | 26.0 | 2.92 | |

5 rows × 21 columns

```
# Proportion des céréales entre l'alimentation humaine et animale

# grouper par produit
df_cereales = df_cereales.groupby('Produit', as_index=False)[
    ['Aliments pour humains',
    'Aliments pour animaux']].sum()

#total par céréale
df_cereales['Total_cereales'] = df_cereales['Aliments pour humains'] + df_cereales['Aliments pour animaux']

# Calcul des pourcentages
df_cereales['Prop_humains (%)'] = round((df_cereales['Aliments pour humains']/df_cereales['Total_cereales'])*100, 2)
df_cereales['Prop_animaux (%)'] = round((df_cereales['Aliments pour animaux']/df_cereales['Total_cereales'])*100, 2)

# liste ordonnées sur les céréales les plus distribués pour les humains
df_cereales = df_cereales.sort_values('Prop_humains (%)', ascending=False)

# Création d'un graphique à barre empilée pour montrer pour chaque produit la part animale et humaine
ax = df_cereales.plot(kind='bar', x='Produit', y=['Prop_humains (%)', 'Prop_animaux (%)'], stacked=True)
ax.legend(['Part humaine', 'Part animale'], loc='right', bbox_to_anchor=(1.5, 0.8))
plt.title('Part des céréales - Alimentation humaine vs animale')
plt.xlabel('')
plt.ylabel('%')
plt.show()
```

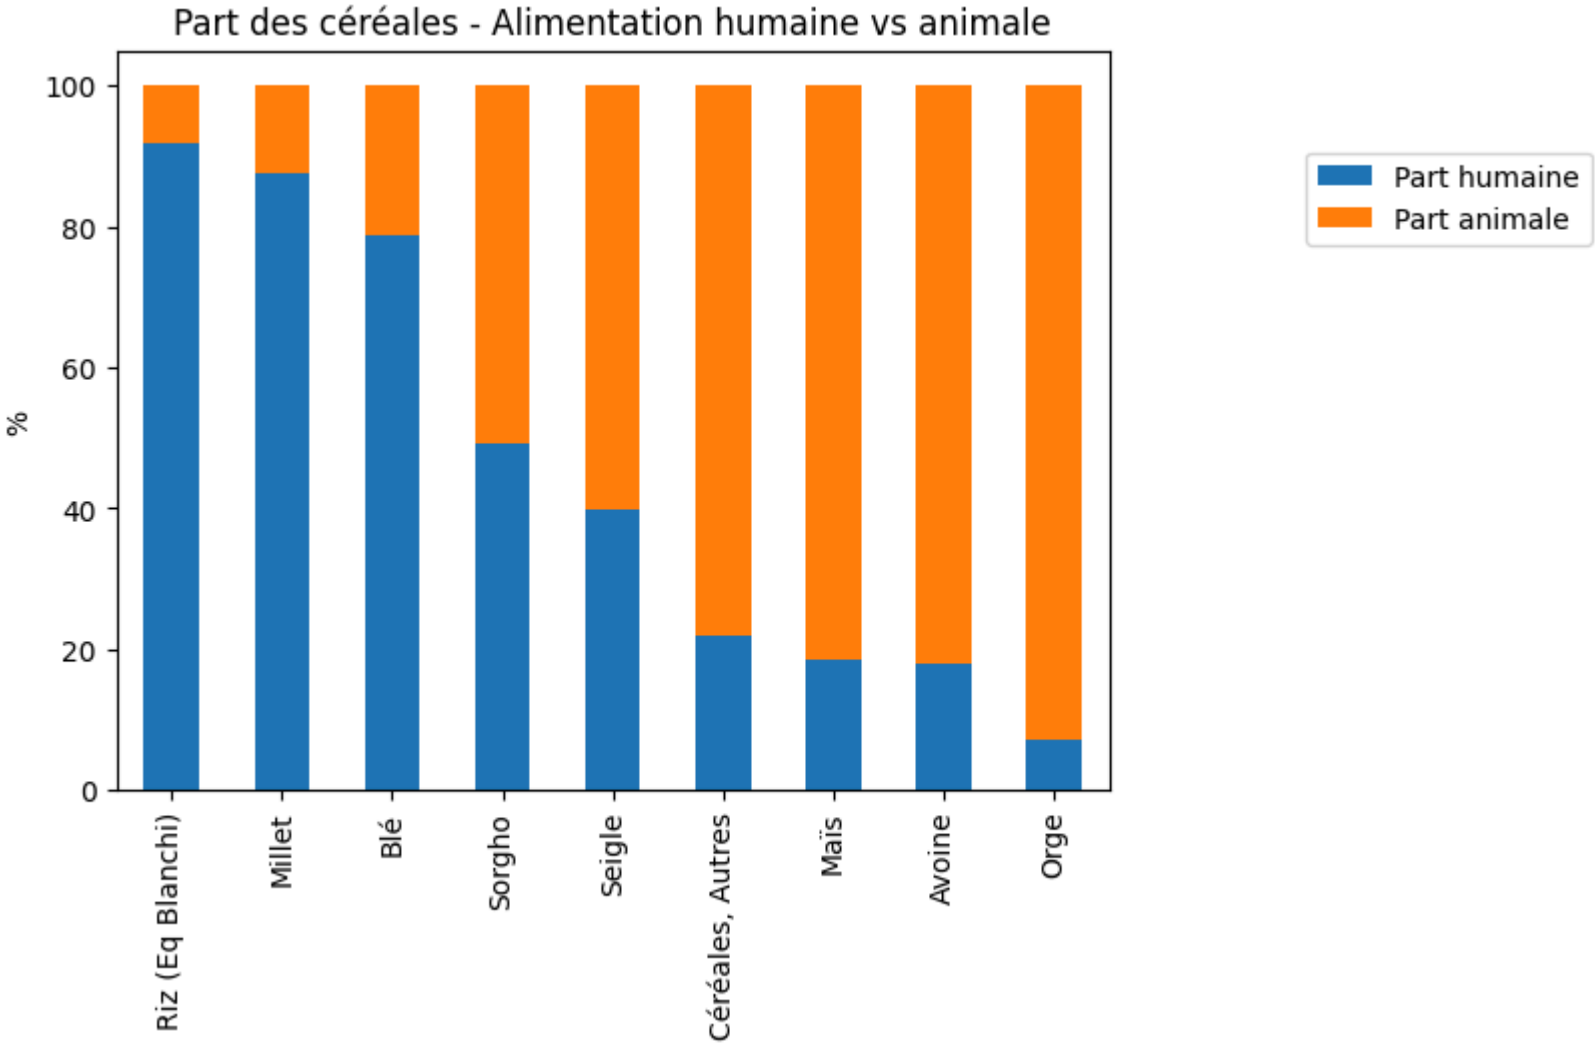


## 3.6 - Pays avec la proportion de personnes sous-alimentée la plus forte en 2017

```
#Création de la colonne proportion par pays (autre test)

# Calculer le total de kcal par habitant par pays sum(Disponibilité_kcal), groupby('Zone')
# faire un classement croissant où le plus faible pourcentage représente le pays le plus sous-alimenté
```

```
prop_kcal_quantite_pays = df_population_dispo_alimentaire_2017.groupby('Zone')['Disponibilité alimentaire (Kcal/personne
prop_kcal_quantite_pays['Prop_pays_sous_alimentee(%)'] = prop_kcal_quantite_pays['Total_Kcal_hab_pays'] / population_dis

prop_kcal_quantite_pays['Prop_pays_sous_alimentee(%)'] = round((prop_kcal_quantite_pays['Prop_pays_sous_alimentee(%)'])*

# On merge à la dataframe originale pour de futures analyses
df_population_dispo_alimentaire_2017 = df_population_dispo_alimentaire_2017.merge(prop_kcal_quantite_pays, on='Zone')


#affichage après trie des 10 pires pays
# drop duplicates -> les données sont déjà aggrégés par zone dans la dataframe originale
liste_10_pire_pays = df_population_dispo_alimentaire_2017.drop_duplicates(subset=['Zone'])[
    ['Zone', 'Total_Kcal_hab_pays', 'Prop_pays_sous_alimentee(%)']
    ]
liste_10_pire_pays = liste_10_pire_pays.sort_values('Prop_pays_sous_alimentee(%)', ascending=True).head(10)
liste_10_pire_pays['Zone'] = liste_10_pire_pays['Zone'].replace({
    'République populaire démocratique de Corée': 'Corée du Nord'
})

liste_10_pire_pays['Diff_kcal_jour_hab'] = population_dispo_alimentaire_merge['Dispo_kcal_mondial_personne_jour'].iloc[0

# Diagramme en barre empilée pour montrer la part calorique pour chaque pays (en rouge)
# et la différence entre la part calorique disponible mondiale et la part pour chaque pays
ax = liste_10_pire_pays.plot(x='Zone',
                             y=['Total_Kcal_hab_pays', 'Diff_kcal_jour_hab'],
                             kind='bar',
                             color=['#E57373', '#81C784'],
                             stacked=True)
plt.xticks(rotation=90)
plt.xlabel("")
plt.ylabel('Disponibilité alimentaire (Kcal/personne/jour)')
ax.legend(['Total kcal par habitant par pays', 'Total kcal par habitant recommandé'], loc='right', bbox_to_anchor=(1.8,
plt.show()
```

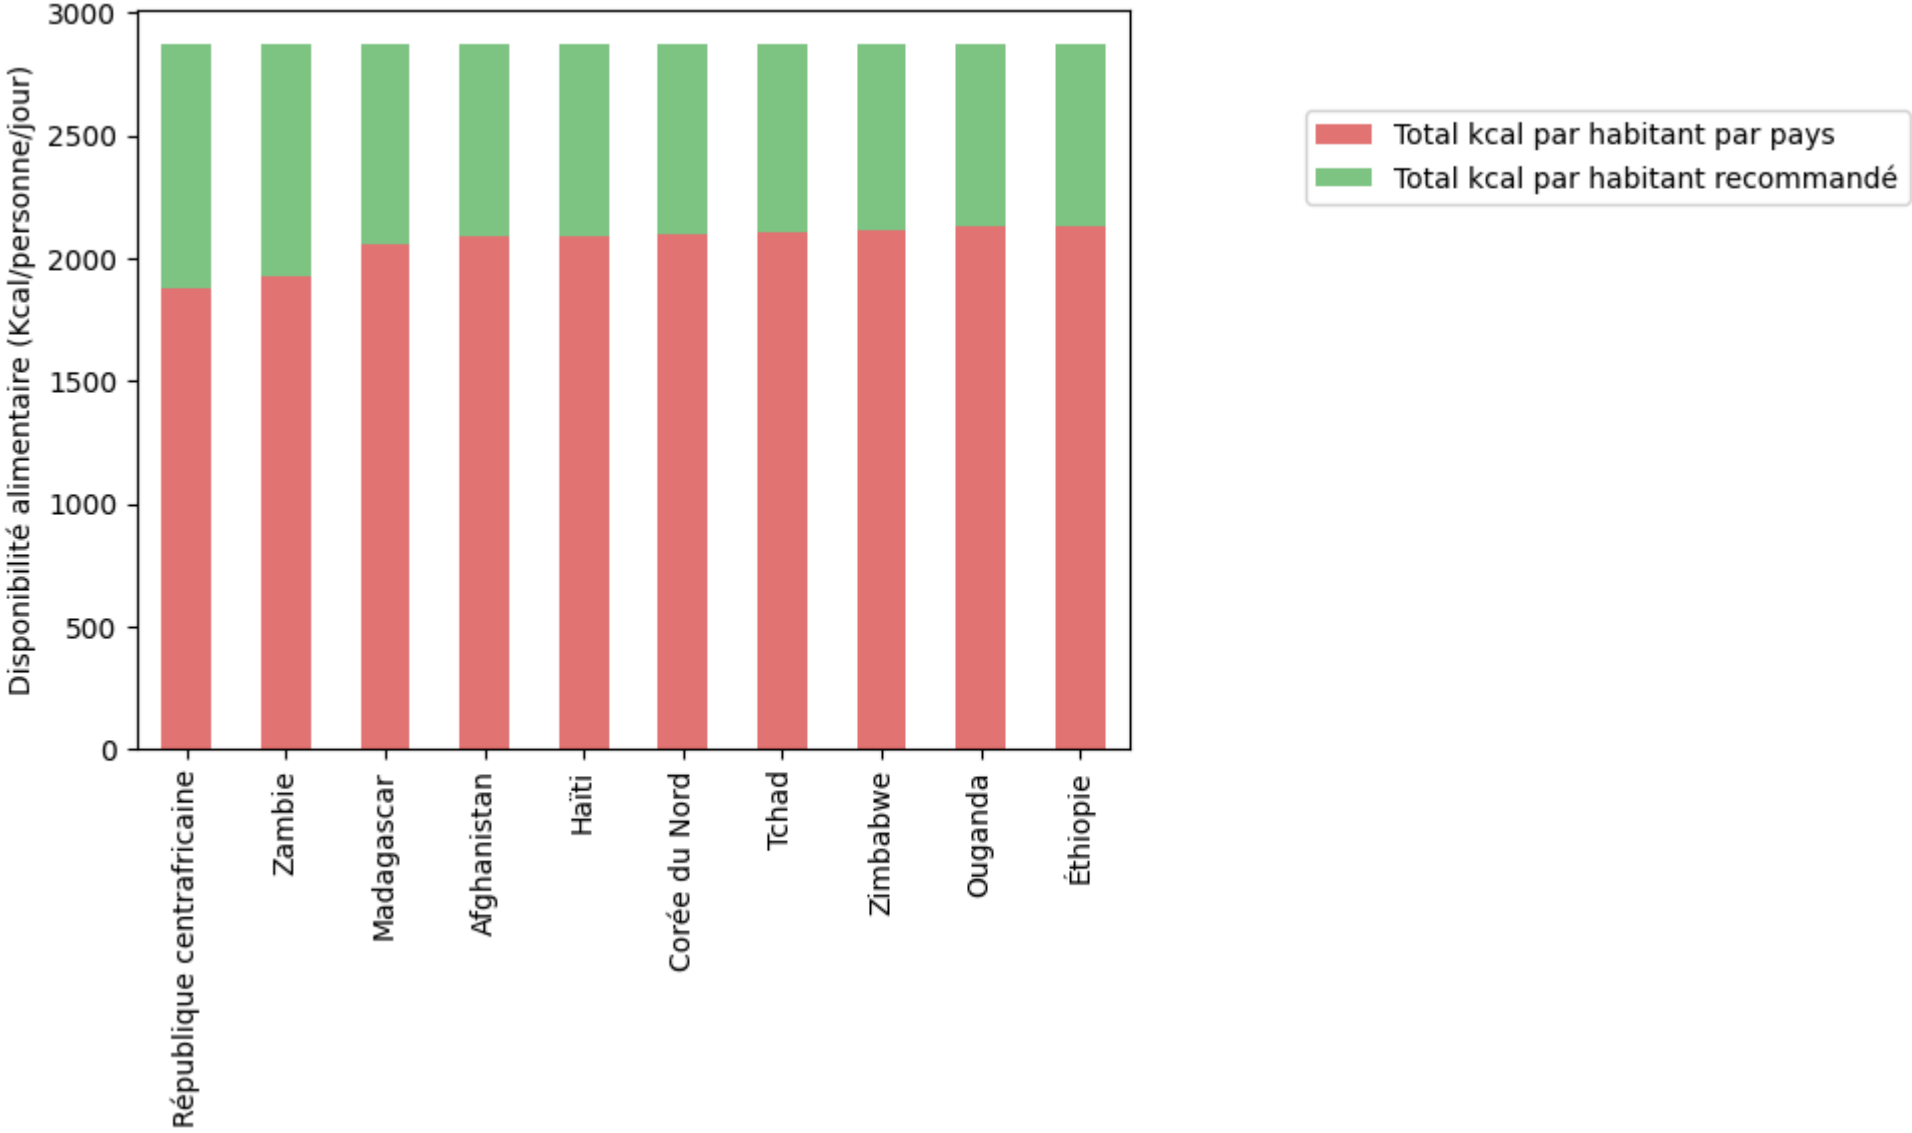


## 3.7 - Pays qui ont le plus bénéficié d'aide alimentaire depuis 2013

```
#calcul du total de l'aide alimentaire par pays
columns_zone_annee_aide = ['Zone', 'Année', 'Aide_alimentaire']
df_zone_annee_aide = aide_alimentaire.loc[(aide_alimentaire['Année'] >= 2013) & (aide_alimentaire['Année'] <= 2016),
    columns_zone_annee_aide]
total_aide_alimentaire_pays = df_zone_annee_aide.groupby('Zone')['Aide_alimentaire'].sum().reset_index()


#affichage après trie des 10 pays qui ont bénéficié le plus de l'aide alimentaire
total_aide_alimentaire_pays["Montant_aide (en T de produits)"] = total_aide_alimentaire_pays['Aide_alimentaire']

total_aide_alimentaire_pays["Montant_aide (en milliards de T de produits)"] = round(total_aide_alimentaire_pays["Montant_
total_aide_alimentaire_10pays = total_aide_alimentaire_pays.sort_values("Montant_aide (en milliards de T de produits)", 
total_aide_alimentaire_10pays = total_aide_alimentaire_10pays.loc[:, ['Zone', 'Montant_aide (en milliards de T de produi
total_aide_alimentaire_10pays.head(10)
```

| | Zone | Montant_aide (en milliards de T de produits) |
|---|---|---|
| **50** | République arabe syrienne | 1.86 |
| **75** | Éthiopie | 1.38 |
| **70** | Yémen | 1.21 |
| **61** | Soudan du Sud | 0.70 |
| **60** | Soudan | 0.67 |
| **30** | Kenya | 0.55 |
| **3** | Bangladesh | 0.35 |
| **53** | République démocratique du Congo | 0.29 |
| **59** | Somalie | 0.29 |
| **43** | Niger | 0.28 |

Next steps: Generate code with total_aide_alimentaire_10pays | View recommended plots | New interactive sheet

## 3.8 - Evolution des 5 pays qui ont le plus bénéficiés de l'aide alimentaire entre 2013 et 2016

```
#Création d'un dataframe avec la zone, l'année et l'aide alimentaire puis groupby sur zone et année
grouped_zone_annee_aide = df_zone_annee_aide.groupby(['Zone', 'Année']).agg('sum').reset_index()
```

```
#Création d'une liste contenant les 5 pays qui ont le plus bénéficiées de l'aide alimentaire
df_grouped_5_countries_aide = grouped_zone_annee_aide.groupby(['Zone'])['Aide_alimentaire'].agg('sum').sort_values(ascen
list_5_top_pays_aide = df_grouped_5_countries_aide['Zone']
print(list_5_top_pays_aide)
```

```
0    République arabe syrienne
1                     Éthiopie
2                        Yémen
3                Soudan du Sud
4                       Soudan
Name: Zone, dtype: object
```

```
#On filtre sur le dataframe avec notre liste
df_top_5_pays_aide = df_zone_annee_aide.loc[df_zone_annee_aide['Zone'].isin(list_5_top_pays_aide), ['Zone', 'Année', 'Ai
```

```
# Affichage des pays avec l'aide alimentaire par année
df_top_5_pays_aide = df_top_5_pays_aide.groupby(['Zone', 'Année'])['Aide_alimentaire'].sum().reset_index()
# Création d'une table pivot avec en abscisse les années, en ordonnée les pays et en
df_top_5_pays_aide_pt = df_top_5_pays_aide.pivot_table(index='Zone', columns='Année', values='Aide_alimentaire')

# Avec le .T, je peux inverser la légende et l'abscisse
df_top_5_pays_aide_pt.T.plot(marker='o', figsize=(10,6))
plt.ylabel('en centaines de millions de T de produits')
plt.title("Evolution de l'aide alimentaire")
plt.show()
```

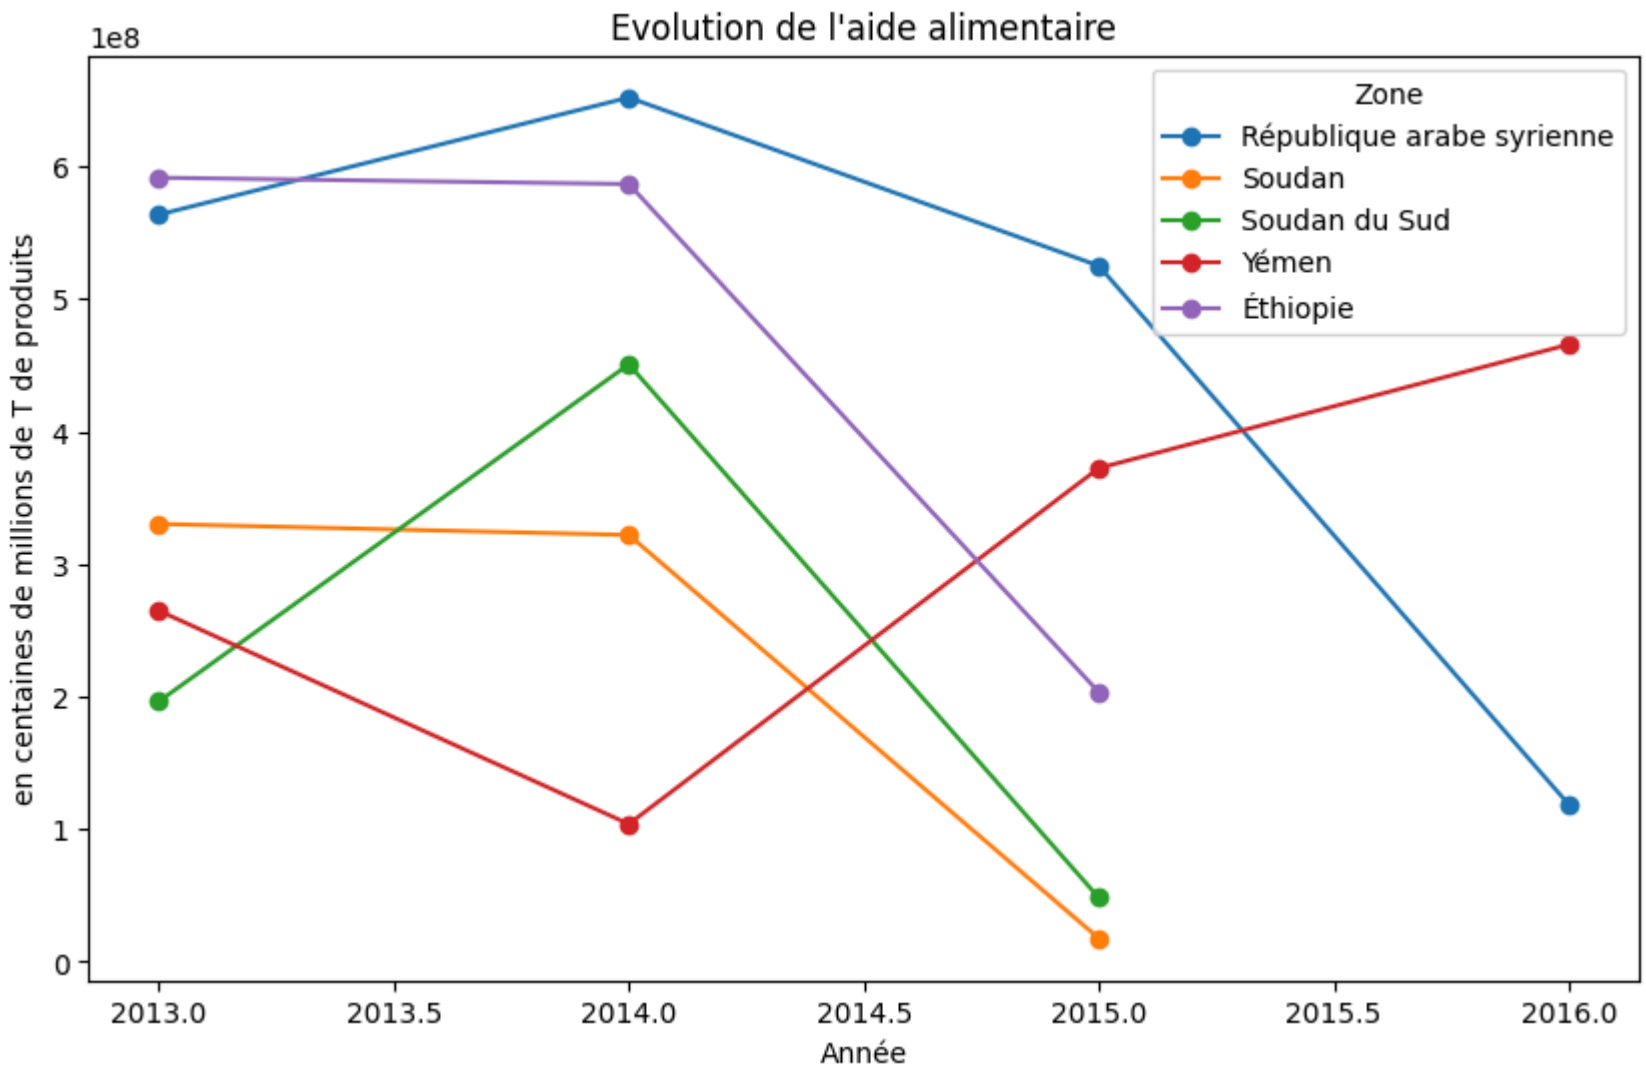


## 3.9 - Pays avec le moins de disponibilité par habitant

```
#Calcul de la disponibilité en kcal par personne par jour par pays
# On additionne toutes les kcal pour chaque produit
```

```
disponibilite_personne_jour_pays = dispo_alimentaire.groupby('Zone')['Disponibilité alimentaire (Kcal/personne/jour)'].a
disponibilite_personne_jour_pays.head()
```

| | Zone | Disponibilité alimentaire (Kcal/personne/jour) |
|---|---|---|
| 0 | Afghanistan | 2087.0 |
| 1 | Afrique du Sud | 3020.0 |
| 2 | Albanie | 3188.0 |
| 3 | Algérie | 3293.0 |
| 4 | Allemagne | 3503.0 |

Next steps: Generate code with disponibilite_personne_jour_pays | View recommended plots | New interactive sheet

```
#Affichage des 10 pays qui ont le moins de dispo alimentaire par personne
bottom_10_pays_dispo_alimentaire_personne = disponibilite_personne_jour_pays.sort_values('Disponibilité alimentaire (Kca
bottom_10_pays_dispo_alimentaire_personne['Diff_kcal'] = population_dispo_alimentaire_merge['Dispo_kcal_mondial_personne
bottom_10_pays_dispo_alimentaire_personne['Zone'] = bottom_10_pays_dispo_alimentaire_personne['Zone'].replace({
    'République populaire démocratique de Corée': 'Corée du Nord'
})
ax = bottom_10_pays_dispo_alimentaire_personne.plot(kind='bar',
                                                    x='Zone',
                                                    y=['Disponibilité alimentaire (Kcal/personne/jour)', 'Diff_kcal'],
                                                     color=['#E57373', '#81C784'],
                                                    stacked=True)
plt.title('Pays avec la plus faible disponibilité alimentaire par habitant par jour')
plt.ylabel('Disponibilité alimentaire (Kcal/personne/jour)')
ax.legend(['Total kcal/personne/jour/pays', 'Total kcal/personne/jour disponible'], loc='right', bbox_to_anchor=(1.8, 0.
plt.xlabel('')
plt.show()
bottom_10_pays_dispo_alimentaire_personne.head(10)
```

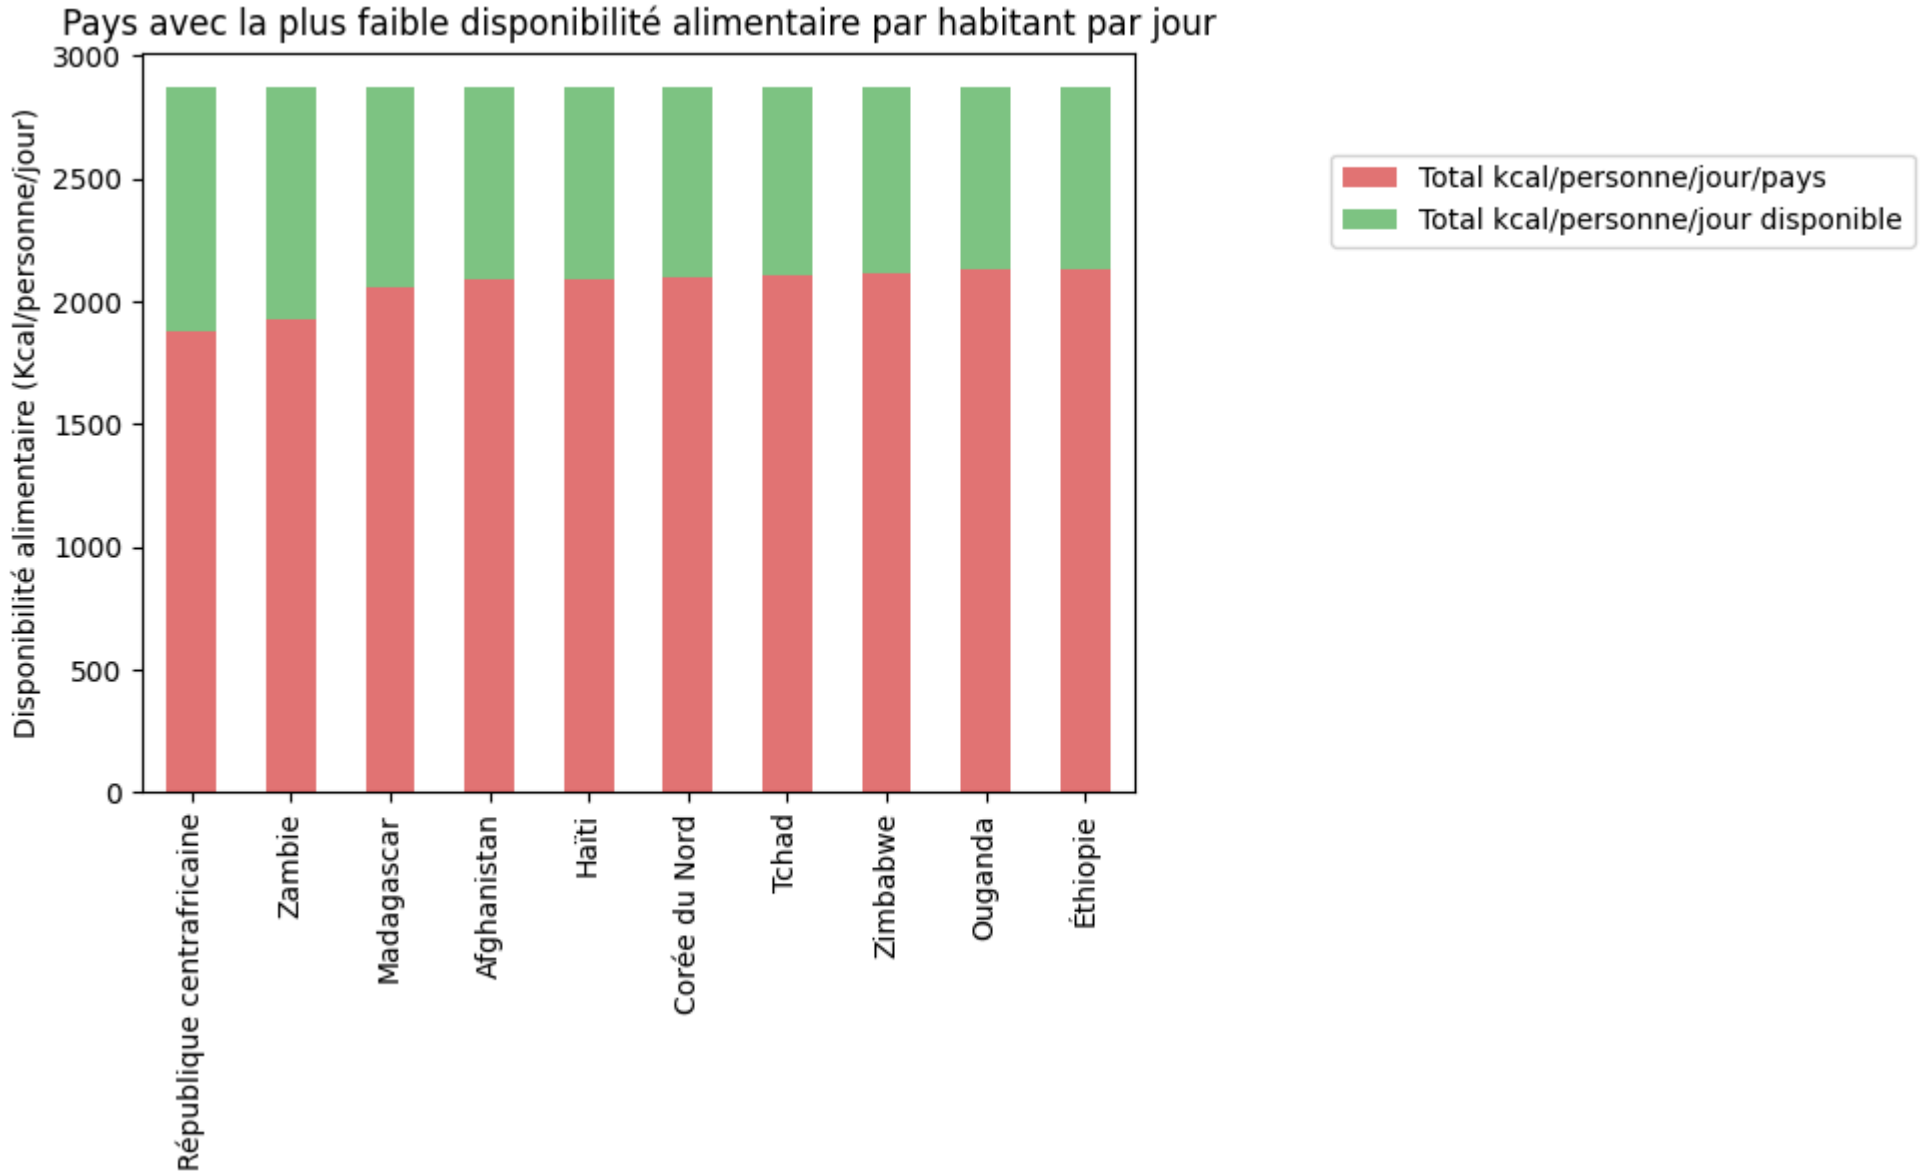


| | Zone | Disponibilité alimentaire (Kcal/personne/jour) | Diff_kcal |
|---|---|---|---|
| **128** | République centrafricaine | 1879.0 | 989.797192 |
| **166** | Zambie | 1924.0 | 944.797192 |
| **91** | Madagascar | 2056.0 | 812.797192 |

| | | | |
|---|---|---|---|
| 91 | Madagascar | 2086.0 | 782.797192 |
| 0 | Afghanistan | 2087.0 | 781.797192 |
| 65 | Haïti | 2089.0 | 779.797192 |
| 133 | Corée du Nord | 2093.0 | 775.797192 |
| 151 | Tchad | 2109.0 | 759.797192 |
| 167 | Zimbabwe | 2113.0 | 755.797192 |
| 114 | Ouganda | 2126.0 | 742.797192 |
| 172 | Éthiopie | 2129.0 | 739.797192 |

Next steps: Generate code with bottom_10_pays_dispo_alimentaire_personne | View recommended plots | New interactive sheet

## 3.10 - Pays avec le plus de disponibilité par habitant

```
#Affichage des 10 pays qui ont le plus de dispo alimentaire par personne
top_10_pays_dispo_alimentaire_personne = disponibilite_personne_jour_pays.sort_values('Disponibilité alimentaire (Kcal/p

# Création d'un bar plot pour montrer la différence
top_10_pays_dispo_alimentaire_personne['kcal_moyenne'] = population_dispo_alimentaire_merge['Dispo_kcal_mondial_personne
top_10_pays_dispo_alimentaire_personne['Diff_kcal'] = top_10_pays_dispo_alimentaire_personne['Disponibilité alimentaire

# Même remarque que pour le premier graphique du même style sauf que la partie en vert représente la part disponible
# chaque habitant au niveau mondial et la partie en rouge le surplus calorique
ax = top_10_pays_dispo_alimentaire_personne.plot(kind='bar',
                                                 x='Zone',
                                                 y=['kcal_moyenne', 'Diff_kcal'],
                                                 stacked=True,
                                               color=['#81C784', '#E57373'])
plt.title('Pays avec le plus de disponibilité alimentaire par habitant par jour')
plt.ylabel('Disponibilité alimentaire (Kcal/personne/jour)')
ax.legend(['Total kcal/personne/jour disponible', 'Total kcal/personne/jour/pays'], loc='right', bbox_to_anchor=(1.8, 0.
plt.xlabel('')
```

```
plt.show()
top_10_pays_dispo_alimentaire_personne.head(10)
```

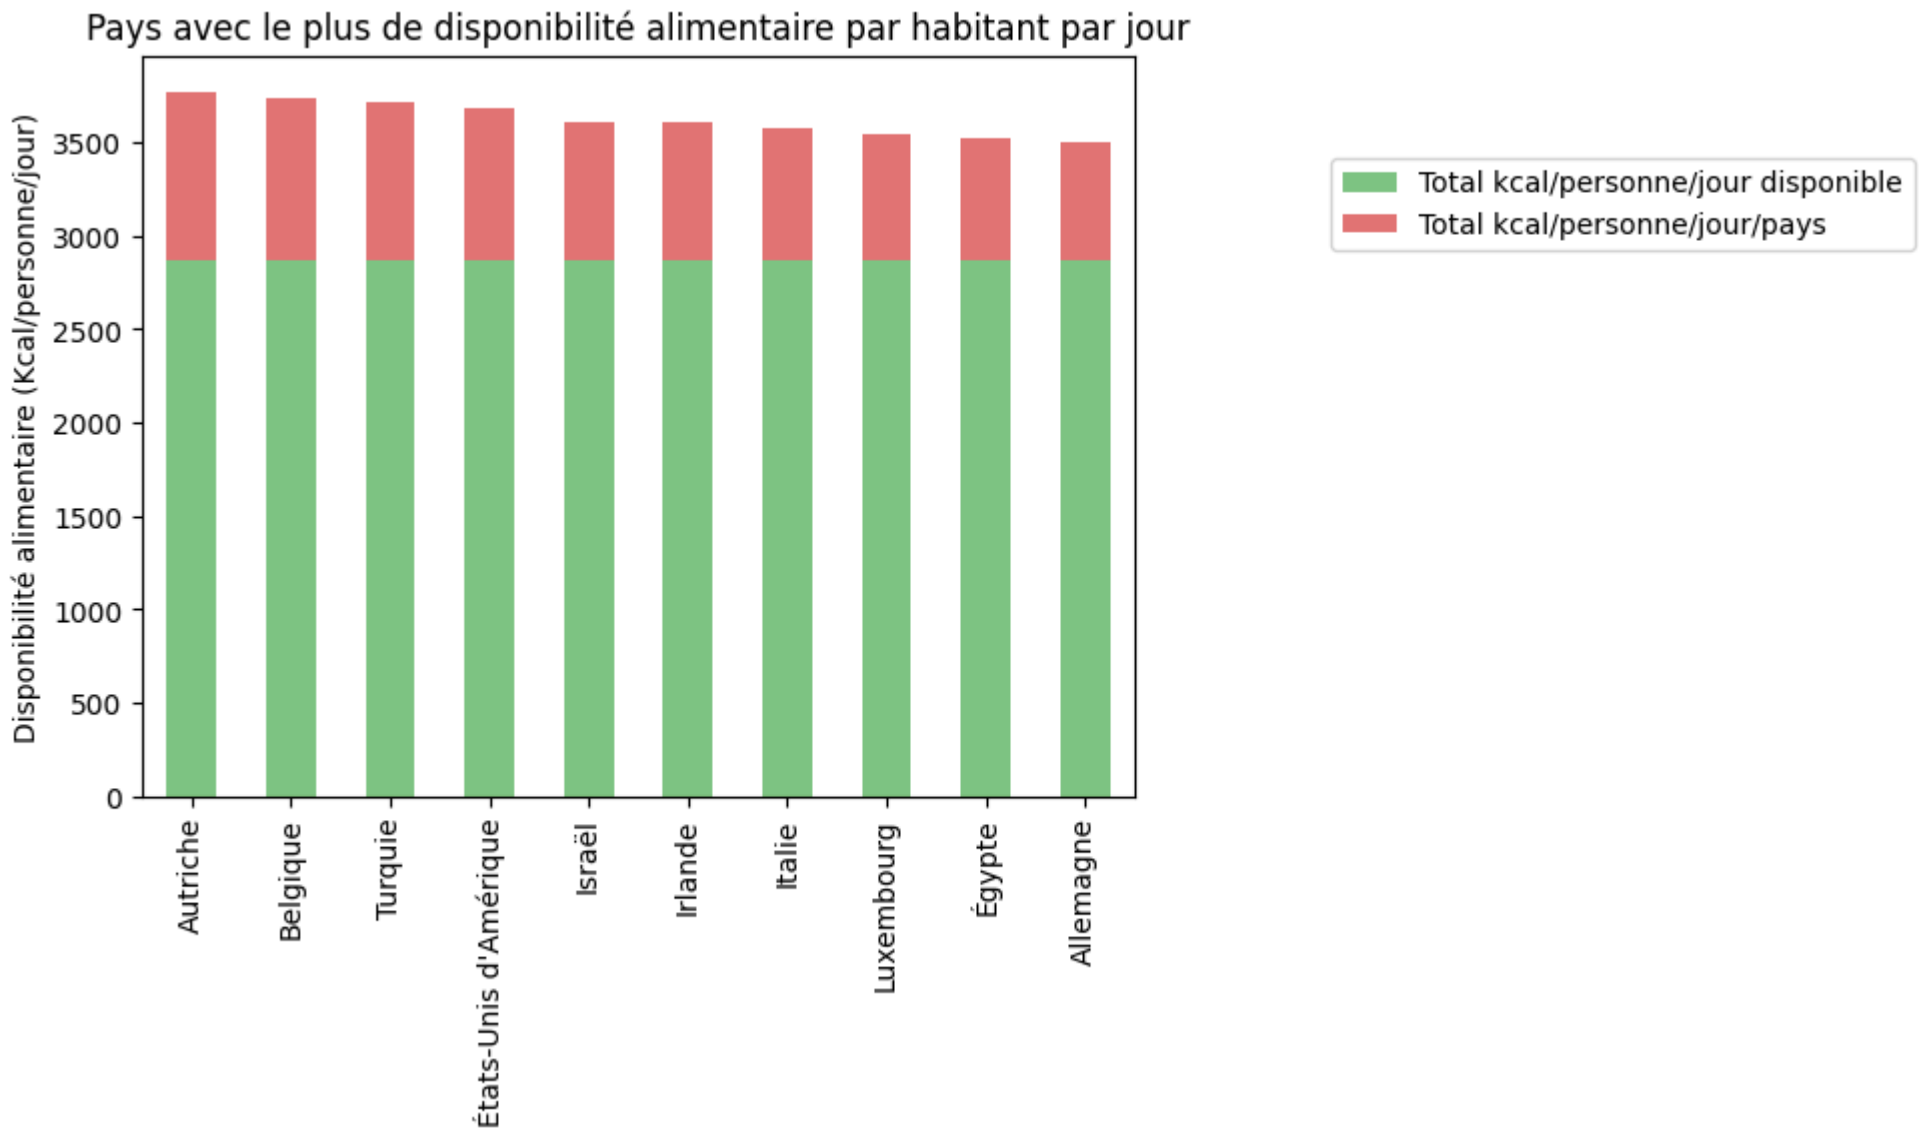


| | Zone | Disponibilité alimentaire (Kcal/personne/jour) | kcal_moyenne | Diff_kcal |
|---|---|---|---|---|
| **11** | Autriche | 3770.0 | 2868.797192 | 901.202808 |
| **16** | Belgique | 3737.0 | 2868.797192 | 868.202808 |
| **159** | Turquie | 3708.0 | 2868.797192 | 839.202808 |

| | | | | |
|---|---|---|---|---|
| **171** | Etats-Unis d'Amérique | 3682.0 | 2868.797192 | 813.202808 |
| **74** | Israël | 3610.0 | 2868.797192 | 741.202808 |
| **72** | Irlande | 3602.0 | 2868.797192 | 733.202808 |
| **75** | Italie | 3578.0 | 2868.797192 | 709.202808 |
| **89** | Luxembourg | 3540.0 | 2868.797192 | 671.202808 |
| **168** | Égypte | 3518.0 | 2868.797192 | 649.202808 |
| **4** | Allemagne | 3503.0 | 2868.797192 | 634.202808 |

Next steps: Generate code with top_10_pays_dispo_alimentaire_personne | View recommended plots | New interactive sheet

```
comparaison_bottom_top_pays_disponibilite = pd.concat([top_10_pays_dispo_alimentaire_personne,bottom_10_pays_dispo_alime
comparaison_bottom_top_pays_disponibilite_srt = comparaison_bottom_top_pays_disponibilite.sort_values('Disponibilité ali
comparaison_bottom_top_pays_disponibilite_srt.plot(kind='barh',
                                                   x='Zone',
                                                   y='Disponibilité alimentaire (Kcal/personne/jour)',
                                                   legend=False,
                                                  color=['#81C784' if x in top_10_pays_dispo_alimentaire_personne['Zone'
plt.title('Comparaison disponibilité alimentaire / habitant - pays riches vs pays pauvres')
plt.xlabel('Disponibilité alimentaire (Kcal/personne/jour)')
plt.ylabel('')
plt.show()
```

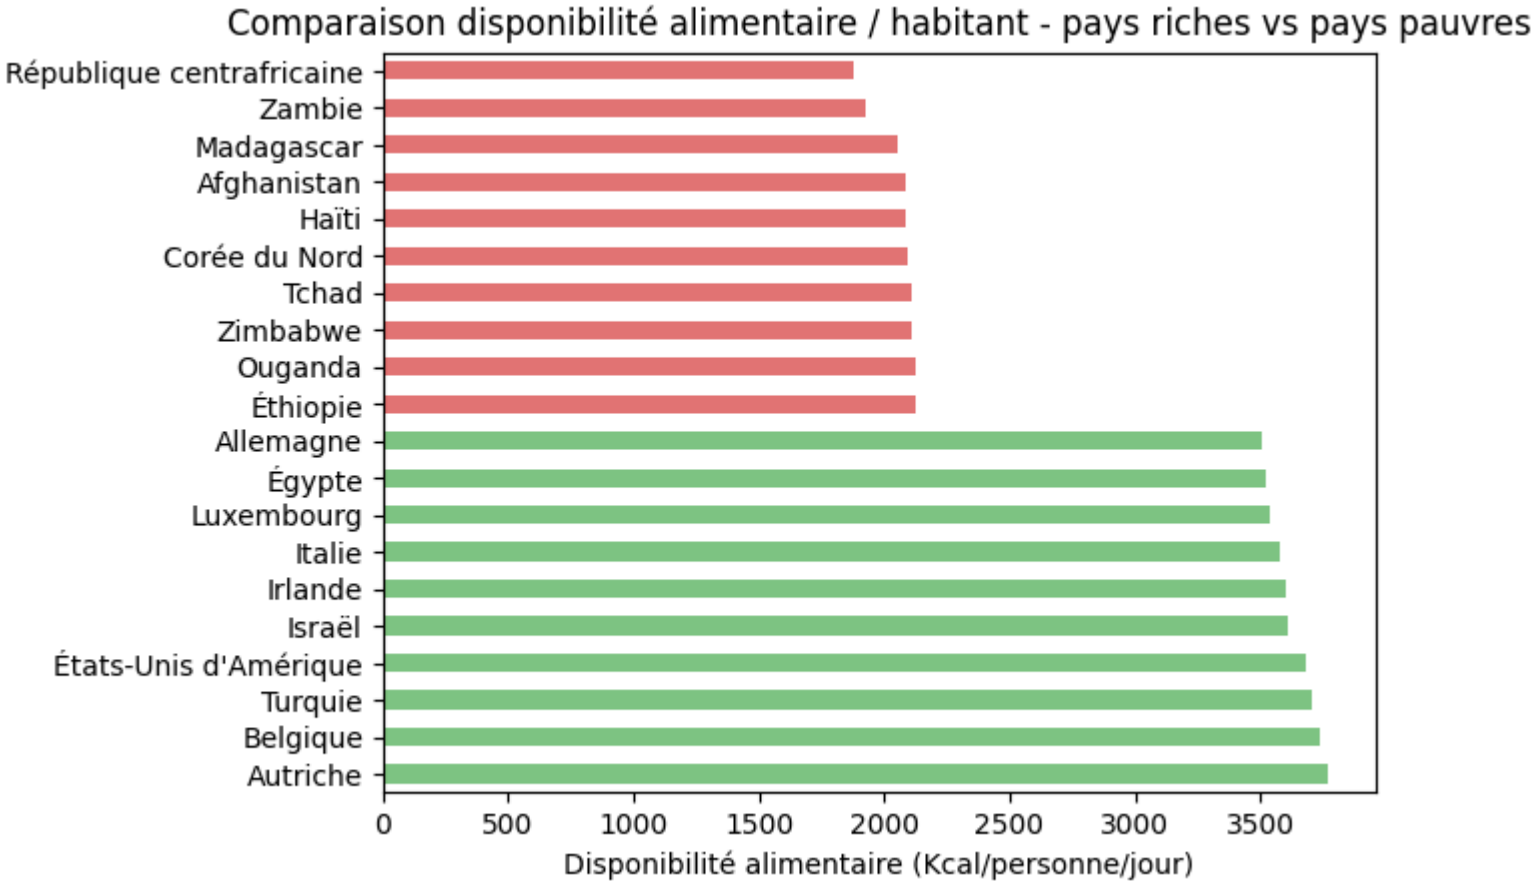


## 3.11 - Exemple de la Thaïlande pour le Manioc

```
#création d'un dataframe avec uniquement la Thaïlande
df_thailande = pd.merge(population_sous_nutrition_merge, dispo_alimentaire, on='Zone')
df_thailande = df_thailande.loc[df_thailande['Zone'] == 'Thaïlande']
df_thailande.head()
```

| | Zone | Année_population | Population | Année_sous_nutrition | Sous_nutrition | Année médian | Produit | Origine | Aliment pou animau |
|---|---|---|---|---|---|---|---|---|---|
| **508176** | Thaïlande | 2013 | 68144518.0 | 2012-2014 | 6200000.0 | 2013 | Abats Comestible | animale | 0 |
| **508177** | Thaïlande | 2013 | 68144518.0 | 2012-2014 | 6200000.0 | 2013 | Agrumes, Autres | vegetale | 0 |
| **508178** | Thaïlande | 2013 | 68144518.0 | 2012-2014 | 6200000.0 | 2013 | Alcool, non Comestible | vegetale | 0 |
| **508179** | Thaïlande | 2013 | 68144518.0 | 2012-2014 | 6200000.0 | 2013 | Aliments pour enfants | vegetale | 0 |
| **508180** | Thaïlande | 2013 | 68144518.0 | 2012-2014 | 6200000.0 | 2013 | Ananas | vegetale | 0 |

5 rows × 23 columns

```
# On calcule la proportion exportée en fonction de la production
df_thailande_manioc_2017 = df_thailande[(df_thailande['Année_population'] == 2017) &
                                  (df_thailande['Produit'] == 'Manioc')]

# On prend uniquement la première ligne car toutes les lignes sont les mêmes
# Mais on ne peut pas supprimer les éléments dupliqués à cause du merge avec
# la dataframe sous-nutrition
df_thailande_manioc_2017 = df_thailande_manioc_2017.head(1)

total_exportations_manioc_thailande = df_thailande_manioc_2017['Exportations - Quantité'].iloc[0]
total_production_manioc_thailande = df_thailande_manioc_2017['Production'].iloc[0]

proportion_export_manioc_total = total_exportations_manioc_thailande / total_production_manioc_thailande

print('Part de manioc exportée en Thailande : {}%'.format(round(proportion_export_manioc_total*100, 2)))
```

```
Part de manioc exportée en Thailande : 83.41%
```

```
# Calcul de la sous nutrition en Thaïlande
```